Universidad Tecnológica de Panamá
Facultad de Ingeniería de Sistemas Computacionales
Licenciatura en ingeniería de Sistemas y Computación

Asignatura:
Tópicos Especiales I

Avance del proyecto final

Autores del proyecto:
Ernesto Jurado 8-1000-963
Tomas Jaramillo 8-996-1931

Grupo 1IL-142

Profesor
José Carlos Rangel Ortiz

8vo Semestre, 2025

Resumen 1
1. Introducción 6
1.1 Antecedentes del problema 6
1.2 Planteamiento y delimitación del problema 7
1.3 Propuesta de Solución 8
1.4 Objetivos 9
1.5 Justificación de la investigación 10
2. Marco teórico 11
2.1. Estado del arte 11
2.2. Conceptos teóricos 12
2.3. Herramientas de Hardware por utilizar 13
2.4. Herramientas de Software por utilizar 14
3. Metodología 15
3.1. Enfoque de investigación 15
3.2. Recolección de datos 16
3.2.1. Construcción del Dataset de Imágenes 16
3.2.2 Herramientas de Etiquetado y Anotación 17
3.2.3. Estrategia de Diversificación de Datos 17
3.2.4. Organización y Estructura del Dataset 17
3.3. Diseño de la propuesta 18
3.3.1. Arquitectura del Sistema 18
3.3.2. Núcleo de Detección YOLO 18
3.3.3. Módulo de Conteo y Validación 18
3.3.4. Explicación del Flujo de Datos 20
3.4. Diseño de la propuesta 21
3.4.1. Diseño de los Experimentos 21
3.4.2. Procedimiento de Recolección 21
3.4.3. Procedimiento de recolección 21

3.4.4. Procedimiento de recolección 22
3.5. Metodos para el procesamiento y análisis de resultados 22
Fuentes bibliográficas 24

Resumen

La investigación se centra en el desarrollo de un sistema de visión artificial para la clasificación y conteo automático de frutas en supermercados, utilizando modelos de aprendizaje profundo como YOLO para identificar múltiples frutas en una sola imagen con alta precisión y en tiempo real. Se emplean cámaras de alta resolución, sistemas de captura con GPU/CPU, y plataformas como Roboflow para el etiquetado y gestión de los datos, integrándose sobre frameworks comAo TensorFlow o PyTorch y programando principalmente en Python y OpenCV para el procesamiento de imágenes.

El proyecto parte del problema de errores humanos y lentitud en la caja en el reconocimiento manual de frutas, proponiendo una solución que automatiza el proceso con un modelo robusto y eficiente, capaz de funcionar en condiciones reales de supermercados, resolviendo retos como oclusión, variabilidad visual y agrupamientos.

La justificación radica en la mejora operativa y de experiencia de usuario, así como la modernización del sector minorista, validándose con antecedentes y estado del arte que demuestran que estas tecnologías han alcanzado madurez y precisión superiores al 90% en aplicaciones reales y experimentales. La solución está delimitada a tres frutas comunes y busca integrarse en sistemas comerciales, sentando bases para innovación y mayor automatización en el sector.

1. Introducción

1.1 Antecedentes del problema

La clasificación automática de frutas mediante visión artificial representa un importante avance hacia la optimización del servicio y la búsqueda de sistemas más eficaces y escalables en el sector alimentario. El tiempo requerido para identificar y cuantificar productos en entornos de supermercado ha constituido un desafío constante que ha impulsado el desarrollo de tecnologías orientadas a resolver este problema. [1]

La automatización de este servicio de identificación de frutas surge por las limitaciones de los métodos actuales. En los sistemas de checkout en la actualidad las frutas y verduras deben ser identificadas manualmente por el cajero o el cliente. Este proceso tiene altas posibilidades a errores humanos, consume tiempo considerable y puede resultar inclusive pérdidas económicas para los establecimientos comerciales debido a identificaciones incorrectas. [2]

La problemática se acentúa en los sistemas de autoservicio, donde aproximadamente tres de cada diez clientes que portan frutas y verduras en su canasta evitan utilizar estos sistemas debido a la complejidad del proceso de selección. Los estudios demuestran que los consumidores requieren entre 10 a 15 segundos en promedio para seleccionar correctamente un producto fresco de una lista de selección, mientras que los artículos más difíciles de encontrar pueden tomar hasta 20 segundos. [3]

El desarrollo de sistemas de visión artificial para clasificación de frutas ha evolucionado considerablemente desde sus inicios. Los primeros enfoques se basaron en técnicas de procesamiento de imágenes tradicionales que utilizaban características como color, textura y morfología para la identificación. Sin embargo, estos métodos presentaban limitaciones significativas en entornos reales debido a variaciones en iluminación, oclusión parcial y similitudes visuales entre diferentes tipos de frutas. [4]

La introducción del aprendizaje profundo marcó un punto de inflexión en este campo. Las redes neuronales convolucionales (CNN) demostraron capacidades superiores para el reconocimiento de patrones complejos en imágenes de frutas, logrando precisiones significativamente más altas que los métodos tradicionales. Específicamente, los algoritmos basados en YOLO (You Only Look Once) han emergido como una solución prometedora para la detección y clasificación de frutas en tiempo real, siendo capaces de procesar múltiples objetos simultáneamente en una sola imagen. [2]

La implementación práctica de estos sistemas en entornos comerciales ha sido validada por grandes cadenas de supermercados. Aldi Süd, por ejemplo, ha implementado exitosamente sistemas de reconocimiento automático de frutas y verduras utilizando cámaras con visión e inteligencia artificiales en sus sistemas de autoservicio. Los

resultados muestran una reducción del tiempo de identificación de productos de aproximadamente 75%, pasando de 10-15 segundos a solo 3 segundos por artículo. [2]

Los beneficios documentados de estos sistemas incluyen mejoras en la experiencia del cliente, reducción de inventario perdido, disminución de tiempos de espera y aumento en la adopción de sistemas de autoservicio. Desde la perspectiva operacional, los retailers reportan una reducción del 50% en intervenciones del personal relacionadas con productos frescos y una disminución similar en el tiempo requerido para manejar las intervenciones restantes.

El contexto tecnológico actual presenta oportunidades sin precedentes para el desarrollo de sistemas más robustos. La disponibilidad de herramientas como YOLO para detección de objetos, Roboflow para gestión de conjuntos de datos y etiquetado, y técnicas de etiquetado manual especializado, proporciona un ecosistema completo para el desarrollo de soluciones de visión artificial. Estos avances han democratizado el acceso a tecnologías que anteriormente requerían recursos considerables para su implementación.

La investigación académica ha demostrado consistentemente la viabilidad técnica de estos sistemas. Estudios recientes reportan precisiones superiores al 95% en la clasificación de frutas utilizando arquitecturas CNN optimizadas, mientras que los sistemas basados en YOLO han logrado valores de precisión media promedio (mAP) de hasta 0.957 en conjuntos de datos de cítricos. Estos resultados validan la madurez tecnológica necesaria para implementaciones comerciales exitosas. [5]

La convergencia de estos factores - necesidad comercial, avances tecnológicos y validación práctica - establece el contexto ideal para investigaciones enfocadas en la optimización de sistemas de clasificación automática de frutas, particularmente utilizando las herramientas y metodologías más avanzadas disponibles en la actualidad.

1.2 Planteamiento y delimitación del problema

El proceso de clasificación y conteo de frutas en supermercados constituye un reto relevante dentro del ámbito de la visión artificial y el aprendizaje automático debido a las características particulares de estos productos y el entorno en el que deben ser reconocidos. Tradicionalmente, los sistemas de reconocimiento se han basado en el escaneo manual de códigos de barras o en la selección por parte del consumidor, generando obstáculos como errores humanos, pérdidas económicas por mal etiquetado o fraude, y una experiencia de usuario deficiente en estaciones de autoservicio. [6]

El principal problema radica en la incapacidad de los métodos actuales para identificar de manera automática y precisa diversas frutas en una sola imagen, especialmente en situaciones donde varios objetos se superponen, existen variaciones de color, forma y textura debido a factores estacionales o condiciones de luz, y se presentan interferencias del entorno

físico. Además, el conteo exacto de frutas en una imagen sigue siendo un desafío cuando existe oclusión parcial, agrupamiento denso de objetos y presencia de elementos de fondo. [7]

A pesar de los avances en algoritmos de detección y clasificación, como YOLO y arquitecturas de redes neuronales profundas, persisten limitaciones en la robustez del sistema frente a entornos complejos, la generalización en presencia de variabilidad intraclase (frutas del mismo tipo con diferencias visuales), y la necesidad de soluciones eficientes en términos de tiempo y recursos computacionales. Los sistemas actuales, si bien alcanzan altas tasas de precisión, pueden mostrar disminución en el rendimiento en escenarios reales cuando los objetos se encuentran parcialmente cubiertos, agrupados o bajo condiciones no ideales de iluminación.

Delimitación:

Este trabajo se centra en desarrollar e investigar un sistema de visión artificial capaz de detectar, clasificar y cuantificar tres tipos de frutas comunes presentes en el entorno de supermercados, utilizando una sola imagen como entrada y tomando en cuenta las dificultades derivadas del agrupamiento de objetos, la similitud visual entre clases y las condiciones ambientales habituales de estos espacios. La investigación utilizará técnicas basadas en YOLO para detección y conteo, herramientas de gestión y etiquetado de datos como Roboflow, y procedimientos de etiquetado manual, limitándose a experimentar únicamente con imágenes obtenidas en escenarios representativos de supermercados, permitiendo así evaluar la viabilidad y precisión del sistema en un contexto práctico y acotado. [8]

Esta delimitación busca abordar específicamente el problema de la clasificación y conteo visual de frutas de manera automática y precisa, excluyendo análisis de calidad, grado de madurez o funcionamiento con frutas exóticas o poco comunes. La solución propuesta atenderá a la demanda de automatización del proceso de registro de frutas en supermercados, contribuyendo a mejorar la eficiencia operativa y la satisfacción del cliente.

1.3 Propuesta de Solución

La solución planteada para el problema de clasificación y conteo automático de frutas en supermercados se basa en un sistema de visión artificial que emplea la arquitectura YOLO (You Only Look Once) como núcleo del modelo de detección y clasificación. Esta solución integra técnicas avanzadas de aprendizaje profundo para reconocer múltiples frutas en una sola imagen, cuantificarlas con alta precisión, y operar en tiempo real para su aplicación práctica en entornos comerciales. [9]

El sistema propuesto utilizará imágenes capturadas por cámaras instaladas en puntos estratégicos que permitan visualizar la superficie del área donde se presentan las frutas (por ejemplo, mostradores o cajas automáticas). Gracias a la capacidad de YOLO para detectar y localizar objetos simultáneamente en la imagen, se podrá identificar cada fruto, clasificarlo en las categorías predefinidas y contar la cantidad con exactitud.

Se empleará Roboflow como plataforma para la gestión del conjunto de datos y el etiquetado humano de las imágenes de frutas. Esta herramienta facilita la creación de datos anotados con alta calidad, así como el preprocesamiento y el aumento de datos, aspectos esenciales para mejorar la robustez del modelo y reducir la necesidad de grandes cantidades de imágenes.

En el proceso de entrenamiento del modelo se utilizarán imágenes con variabilidad en términos de iluminación, posición, y agrupamiento de las frutas para aumentar la capacidad del sistema de generalizar en condiciones reales. Además, el etiquetado humano permitirá la generación de datos que mejor representen los escenarios del supermercado, incluyendo casos con oclusión y distintas texturas y colores.

La implementación técnica considerará aspectos como la optimización para dispositivos con recursos limitados, garantizando que el sistema pueda ser integrado en hardware comúnmente disponible en supermercados (PCs o cámaras inteligentes), manteniendo un balance entre velocidad y precisión. La solución propuesta apunta a alcanzar una precisión superior al 95% en clasificación y conteo, siguiendo estándares comprobados en investigaciones similares. [10]

Finalmente, se plantea que esta solución pueda ser integrada en las estaciones de autoservicio o sistemas de inventario de los supermercados, aportando beneficios tangibles como la reducción del tiempo de atención, disminución de errores en la facturación y una experiencia de usuario mejorada. Esto contribuye no solo a la eficiencia operativa sino también a aumentar la confianza del consumidor en los métodos automáticos de pago.

- Uso de YOLO para detección y clasificación en tiempo real de tres frutas comunes.
- Empleo de Roboflow y etiquetado manual para construir un dataset robusto.
- Entrenamiento del modelo en condiciones variadas para mejorar su generalización.
- Optimización para funcionamiento eficiente en hardware típico de supermercados.
- Integración hacia aplicaciones prácticas en autoservicio y control de inventario.

1.4 Objetivos

Objetivo General

Desarrollar e implementar un sistema de visión artificial basado en la arquitectura YOLO para la detección, clasificación y conteo automático de tres tipos de frutas comunes en supermercados, utilizando una sola imagen como entrada, con el fin de mejorar la eficiencia y precisión en el proceso de registro y facturación de productos frescos.

Objetivos Específicos

- Construir un conjunto de datos anotados que incluya imágenes representativas de las frutas seleccionadas, empleando herramientas de etiquetado manual y automatizado como Roboflow para asegurar la calidad y diversidad del dataset.
- Entrenar y optimizar un modelo de detección de objetos basado en YOLO para identificar y clasificar las frutas en condiciones reales de supermercado, considerando variaciones de iluminación, oclusiones y agrupamiento.
- Implementar un módulo de conteo automático que permita cuantificar de manera precisa la cantidad de frutas detectadas en una sola imagen, incluso cuando hay objetos superpuestos o parcialmente ocultos.
- Validar el sistema mediante pruebas en imágenes capturadas en entornos simulados de supermercado, evaluando métricas clave como precisión, recall y tiempo de procesamiento para asegurar su viabilidad práctica.
- Proponer recomendaciones para la integración del sistema en estaciones de autoservicio o procesos de inventario en supermercados, destacando beneficios operativos y mejoras en la experiencia del usuario.

Estos objetivos están alineados con investigaciones previas que han demostrado la eficacia del uso de redes neuronales convolucionales y modelos YOLO para clasificación y conteo de frutas, apuntando a una automatización confiable y escalable en el sector retail. [8][9]

1.5 Justificación de la investigación

La presente investigación resulta fundamental debido a la creciente necesidad de optimizar los procesos de identificación y registro de frutas en supermercados, un aspecto clave para mejorar la eficiencia operativa y la experiencia del cliente. La visión artificial aplicada a este ámbito permite automatizar tareas que tradicionalmente dependen del reconocimiento manual, reduciendo errores humanos, agilizando el proceso de pago y disminuyendo pérdidas económicas asociadas a fraudes o etiquetados incorrectos. [11]

Además, la adopción de tecnologías que permitan clasificar y contar automáticamente frutas a partir de imágenes contribuye a la modernización y competitividad de los supermercados, en línea con tendencias globales de digitalización y automatización en el comercio minorista. Este avance tecnológico impacta positivamente en la reducción de tiempos de espera y mejora notablemente la precisión en la gestión de inventarios y la facturación.

El empleo de técnicas de aprendizaje profundo y modelos como YOLO en sistemas de visión artificial ha demostrado ser altamente efectivo para tareas similares, garantizando una alta precisión y velocidad de procesamiento, aspectos cruciales para su implementación práctica en entornos con alta rotación de clientes. Esto posiciona a la visión artificial como una herramienta estratégica para responder a las demandas actuales del sector retail.

Por último, la investigación contribuye al desarrollo científico y tecnológico al explorar el uso de herramientas especializadas como Roboflow para la anotación de datos y el entrenamiento de modelos, así como a la aplicación de metodologías robustas que permitirán validar la viabilidad y efectividad de la propuesta en un contexto realista. Este aporte resulta significativo tanto para la academia como para la industria, sentando bases para futuras innovaciones en automatización de procesos comerciales.

En resumen, esta investigación justifica su realización en la mejora integral de procesos logísticos y comerciales en supermercados mediante la automatización inteligente, con beneficios evidentes en eficiencia, exactitud, experiencia de usuario y competitividad empresarial.

2. Marco teórico

2.1. Estado del arte

La clasificación automática de frutas mediante visión artificial ha sido objeto de diversas investigaciones que buscan optimizar la detección, clasificación y evaluación de la calidad de productos frescos en entornos agrícolas y comerciales. Desde los primeros métodos basados en procesamiento de imágenes clásicas y extracción de características como color y textura, hasta los modernos enfoques basados en redes neuronales convolucionales (CNN) y modelos de detección en tiempo real como YOLO, el panorama tecnológico ha avanzado significativamente en los últimos años. [12]

Diversos estudios han demostrado que el uso de arquitecturas CNN permite superar las limitaciones de los métodos tradicionales, logrando una mayor precisión y robustez ante variaciones de iluminación, oclusión parcial y diversidad visual dentro de una misma clase de fruta. Por ejemplo, investigaciones que aplican YOLO versiones recientes reportan precisiones superiores al 90% en la clasificación y detección de diversos tipos de frutas, además de capacidades para procesar múltiples objetos simultáneamente en imágenes complejas.

Un caso destacado es la aplicación de visión artificial y modelos YOLO para la clasificación del estado de madurez en arándanos, donde se logró una precisión del 95% en la identificación de las etapas inmaduro, pintón y maduro, lo que ejemplifica el potencial de estas tecnologías para aplicaciones comerciales y agrícolas. De manera similar, sistemas diseñados para supermercados han implementado cámaras con IA para reconocer frutas y verduras en básculas de autoservicio, acelerando significativamente el proceso de identificación y pago, además de reducir errores y pérdidas. [13]

En el ámbito comercial, el uso de sistemas de visión artificial para la clasificación y conteo automático de frutas representa un avance estratégico que impacta en la eficiencia operativa

y la experiencia del cliente. Empresas y supermercados internacionales han adoptado soluciones que integran cámaras e IA para este fin, con resultados que mejoran los tiempos de atención y la precisión en la facturación. Esta tendencia evidencia la madurez de las tecnologías actuales y la viabilidad de su aplicación en contextos de alta demanda y variabilidad.

En resumen, la literatura y casos prácticos recientes confirman que los modelos de aprendizaje profundo, particularmente YOLO y sus variantes, junto con plataformas colaborativas para anotación y manejo de datos como Roboflow, configuran el estado del arte en sistemas de clasificación y conteo automático de frutas. Estas soluciones combinan rapidez, precisión y adaptabilidad, elementos claves para su implementación efectiva en supermercados modernos.

2.2. Conceptos teóricos

Visión Artificial

La visión artificial es una rama de la inteligencia artificial que se encarga de otorgar a las máquinas la capacidad de interpretar y comprender imágenes digitales del mundo real. Este campo combina técnicas de procesamiento de imágenes, aprendizaje automático y análisis de patrones para permitir la identificación, clasificación y seguimiento de objetos en imágenes o videos. En el contexto de clasificación de frutas, la visión artificial permite automatizar tareas que anteriormente requerían intervención humana, mejorando la precisión y eficiencia. [14]

Aprendizaje Profundo (Deep Learning)

El aprendizaje profundo es una subárea del aprendizaje automático que utiliza redes neuronales artificiales con múltiples capas para modelar y entender datos complejos. Las arquitecturas más comunes en visión artificial son las redes neuronales convolucionales (CNN), que son especialmente adecuadas para analizar imágenes debido a su capacidad para extraer características como bordes, texturas y formas de manera jerárquica y automática. Estas redes permiten entrenar modelos capaces de distinguir entre diferentes tipos de frutas con alta precisión. [15]

YOLO (You Only Look Once)

YOLO es un modelo de detección de objetos en tiempo real que procesa toda la imagen en una sola pasada, lo que permite una alta velocidad de detección sin sacrificar precisión. Este algoritmo divide la imagen en una cuadrícula y predice cuadros delimitadores y probabilidades para cada celda, facilitando la detección simultánea de múltiples objetos. YOLO es ampliamente utilizado en aplicaciones de visión artificial donde se requiere rápida identificación y localización de objetos, como la clasificación de frutas en supermercados. [15]

Etiquetado de Datos (Data Labeling)

El etiquetado de datos es el proceso de asignar etiquetas o anotaciones a imágenes para indicar la presencia y ubicación de objetos de interés. En proyectos de visión artificial, el etiquetado manual o asistido por herramientas especializadas, como Roboflow, es crucial para crear conjuntos de datos de calidad que sirvan para entrenar modelos precisos. Este proceso incluye delimitar con cajas los objetos (en este caso, frutas) y clasificarlos adecuadamente para que el modelo aprenda a reconocerlos. [16]

Conteo Automático de Objetos

El conteo automático se refiere a la capacidad de un sistema para identificar la cantidad exacta de objetos visibles en una imagen. En la clasificación de frutas, este concepto es fundamental para conocer no solo la clase de cada fruta, sino también el número total presente, considerando posibles superposiciones y oclusiones parciales. Los modelos basados en YOLO permiten esta funcionalidad combinando detección y agrupamiento de objetos con técnicas de procesamiento posterior.

Estos conceptos teóricos forman la base sobre la cual se desarrolla el sistema propuesto para la clasificación y conteo automático de frutas en supermercados, facilitando una comprensión integral de las tecnologías y metodologías involucradas. [17]

2.3. Herramientas de Hardware por utilizar

Para el desarrollo y puesta en marcha del sistema de clasificación y conteo automático de frutas en supermercados, se requiere un conjunto específico de herramientas de hardware que permita capturar, procesar y gestionar las imágenes con eficiencia y en tiempo real.

Cámaras de alta resolución

Se utilizarán cámaras digitales con capacidad para capturar imágenes en alta resolución y buena reproducción de color, esenciales para asegurar que los detalles visuales de las frutas (como textura, forma y color) sean claramente capturados. La calidad y velocidad de captura son fundamentales para minimizar errores en la detección y clasificación, especialmente en entornos con múltiples objetos y variabilidad en la iluminación. [15]

Sistema de iluminación controlada

Para garantizar imágenes consistentes y minimizar las variaciones causadas por condiciones de luz ambiental, se puede emplear un sistema de iluminación artificial controlada en la zona de captura. Esto facilita que el sistema de visión mantenga la precisión en la clasificación y conteo, reduciendo la interferencia de sombras o reflejos. [18]

Unidad de procesamiento (GPU/CPU)

El entrenamiento y la inferencia de modelos basados en aprendizaje profundo como YOLO requieren hardware con capacidad computacional adecuada. Se recomienda el uso de unidades de procesamiento gráfico (GPU) modernas para acelerar el procesamiento de imágenes y la ejecución del modelo en tiempo real durante la fase de operación. Sin embargo, para pruebas iniciales, se podrá utilizar procesadores (CPU) potentes con soporte para operaciones paralelas, aunque con menor eficiencia. [19]

Equipos auxiliares de conexión

Inclusión de dispositivos de conexión como cables USB 3.0 o interfaces Ethernet para garantizar la transferencia rápida y confiable de datos desde las cámaras hasta la unidad de procesamiento, así como la integración con otros sistemas del supermercado, como estaciones de autoservicio o servidores de inventario. [11]

El conjunto de hardware descrito asegura una plataforma sólida y confiable para desarrollar y operar el sistema de visión artificial, optimizando el rendimiento y la precisión necesarios para su aplicación en entornos comerciales reales.

2.4. Herramientas de Software por utilizar

Para el desarrollo del sistema de clasificación y conteo automático de frutas mediante visión artificial, se emplearán diversas herramientas de software que permitirán el manejo de datos, el entrenamiento del modelo y la ejecución eficiente en tiempo real.

YOLO (You Only Look Once)

YOLO es la arquitectura principal que se utilizará para la detección y clasificación de objetos (frutas) en imágenes. Su algoritmo permite la identificación simultánea de múltiples objetos y la localización precisa de cada uno en tiempo real, siendo uno de los modelos más eficientes y precisos actualmente empleados en visión artificial. [13]

Roboflow

Roboflow es una plataforma especializada en la gestión y preparación de conjuntos de datos para proyectos de visión artificial. Facilita la carga, anotación (etiquetado), aumentación y organización de imágenes, lo que mejora la calidad del dataset y contribuye a un entrenamiento más efectivo del modelo. Su uso permitirá generar un conjunto de datos representativo y diversificado adaptado a las condiciones reales del supermercado.

Frameworks de aprendizaje profundo (TensorFlow/PyTorch)

Para la creación, entrenamiento y evaluación del modelo YOLO se emplearán frameworks de aprendizaje profundo como TensorFlow o PyTorch, que proporcionan un entorno flexible para implementar redes neuronales convolucionales, optimizar hiperparámetros y realizar

procesamiento en GPU. Estos frameworks cuentan con amplio soporte comunitario y herramientas avanzadas para el desarrollo.

Python

Python será el lenguaje de programación principal debido a su amplia adopción en inteligencia artificial y visión computacional. Además, existen librerías específicas para el manejo de imágenes (OpenCV), entrenamiento de modelos (TensorFlow/PyTorch), y procesamiento de datos que facilitan la integración de todos los componentes del sistema.

OpenCV

OpenCV es una librería libre y de código abierto para procesamiento de imágenes y visión artificial. Se empleará para realizar preprocesamiento de imágenes, segmentación, filtrado y otras operaciones auxiliares que mejoren la calidad y robustez del sistema de detección.

Plataformas para implementación y pruebas

Se utilizarán entornos de desarrollo integrados (IDE) como Visual Studio Code o Jupyter Notebook para la codificación y experimentación del modelo. Además, se prevé la integración final en aplicaciones de escritorio o sistemas embebidos según las necesidades del supermercado, mediante el uso de herramientas que faciliten la ejecución del modelo entrenado. [19]

En conjunto, estas herramientas de software permiten un flujo completo desde la preparación de datos, desarrollo y entrenamiento del modelo hasta la implementación y validación efectiva del sistema de clasificación y conteo automático de frutas. [15][16]

3. Metodología

3.1. Enfoque de investigación

El presente estudio adopta un enfoque cuantitativo para el desarrollo e implementación del sistema de visión artificial basado en la arquitectura YOLO destinado a la detección, clasificación y conteo automático de tres tipos de frutas comunes en supermercados. Esta elección metodológica se fundamenta en la naturaleza objetiva y medible de las variables que caracterizan el desempeño de sistemas de inteligencia artificial aplicados a la visión por computadora.[20]

El enfoque cuantitativo resulta particularmente apropiado para investigaciones en visión artificial y deep learning, ya que permite la evaluación rigurosa del rendimiento del modelo YOLO mediante métricas numéricas específicas como precisión, recall, F1-score, mAP (mean Average Precision) y tiempo de procesamiento. Estas métricas son fundamentales para validar la efectividad del sistema propuesto en condiciones reales de supermercado, donde la

exactitud en la detección y clasificación de frutas es crítica para la implementación práctica. [21]

La metodología cuantitativa se alinea con los estándares establecidos en investigaciones similares sobre sistemas de detección de objetos mediante redes neuronales convolucionales, donde la recolección y análisis de datos numéricos permite establecer comparaciones objetivas entre diferentes configuraciones del modelo y validar su desempeño bajo distintas condiciones experimentales. Estudios previos en el campo de la visión artificial aplicada a productos alimentarios han demostrado la efectividad del enfoque cuantitativo para evaluar la precisión de sistemas automatizados de clasificación. [22]

La selección de este enfoque también se justifica por la necesidad de cuantificar objetivamente variables como la cantidad de frutas detectadas correctamente, el porcentaje de clasificaciones erróneas, y el tiempo requerido para procesar cada imagen. Estos datos numéricos son esenciales para determinar la viabilidad comercial del sistema y su capacidad para mejorar la eficiencia operativa en supermercados. [23]

Además, el enfoque cuantitativo facilita la replicabilidad del estudio y permite la aplicación de técnicas estadísticas avanzadas para el análisis de resultados, características fundamentales en investigaciones de inteligencia artificial donde la validación experimental debe ser rigurosa y libre de sesgos subjetivos. Esta metodología también posibilita la generalización de los resultados obtenidos a partir de conjuntos de datos representativos, permitiendo extrapolar el desempeño del sistema a poblaciones más amplias de imágenes de frutas en diferentes condiciones de supermercado. [24]

3.2. Recolección de datos

La recolección de datos constituye una fase crítica para el desarrollo exitoso del sistema de visión artificial basado en YOLO, ya que la calidad y diversidad del dataset impacta directamente en el rendimiento del modelo. El proceso de recolección se estructura en múltiples etapas que garantizan la obtención de un conjunto de datos robusto y representativo de las condiciones reales encontradas en supermercados.[25]

3.2.1. Construcción del Dataset de Imágenes

La construcción del conjunto de datos anotados incluye imágenes representativas de tres tipos específicos de frutas comunes en supermercados, seleccionadas en función de su frecuencia de venta y relevancia comercial. La metodología de recolección sigue las mejores prácticas

establecidas en investigaciones similares, donde se ha demostrado que la diversidad del dataset es fundamental para entrenar modelos robustos de detección de objetos.[26]

Se implementa un enfoque híbrido que combina recolección manual e imágenes sintéticas para maximizar la representatividad del dataset. Las imágenes se capturan en condiciones controladas que simulan diferentes escenarios de supermercado, incluyendo variaciones en iluminación natural y artificial, diferentes ángulos de captura, y distintas densidades de agrupamiento de frutas. Esta diversificación es esencial para entrenar un modelo que pueda generalizar efectivamente en condiciones reales de operación.[27]

3.2.2 Herramientas de Etiquetado y Anotación

Para el proceso de anotación se emplea Roboflow como herramienta principal de etiquetado, una plataforma especializada que ha demostrado eficacia en proyectos similares de visión artificial aplicada a productos alimentarios. Roboflow ofrece capacidades tanto de etiquetado manual como automatizado, permitiendo la creación de anotaciones precisas mediante cuadros delimitadores (bounding boxes) que identifican la ubicación exacta de cada fruta en las imágenes.[28]

El proceso de anotación sigue estándares establecidos para sistemas YOLO, donde cada imagen requiere etiquetas que especifican la clase del objeto (tipo de fruta), las coordenadas del cuadro delimitador, y metadatos adicionales sobre las condiciones de captura. Estudios previos han demostrado que la consistencia en el etiquetado es crucial para el rendimiento del modelo, por lo que se implementan protocolos de control de calidad que incluyen revisión cruzada de anotaciones.[29]

3.2.3. Estrategia de Diversificación de Datos

La estrategia de recolección incorpora técnicas de aumento de datos (data augmentation) para incrementar la diversidad del dataset sin necesidad de capturar imágenes adicionales. Estas técnicas incluyen rotaciones, cambios en brillo y contraste, recortes aleatorios, y transformaciones geométricas que simulan diferentes condiciones de visualización en supermercados.[30]

Se consideran específicamente las variaciones encontradas en entornos reales de supermercado, como oclusiones parciales entre frutas, superposiciones de objetos, diferentes niveles de iluminación, y backgrounds variables. La literatura especializada indica que estos factores son determinantes para el éxito de sistemas de detección automática en aplicaciones comerciales.[31]

3.2.4. Organización y Estructura del Dataset

El dataset se organiza siguiendo la estructura estándar para entrenamiento de modelos YOLO, dividido en conjuntos de entrenamiento (70%), validación (20%) y prueba (10%) para garantizar una evaluación rigurosa del desempeño del modelo. Esta distribución permite optimizar los hiperparámetros del modelo durante el entrenamiento mientras se mantiene un conjunto independiente para la evaluación final.

Cada imagen del dataset se acompaña de archivos de anotación en formato compatible con la arquitectura YOLO, incluyendo información sobre las coordenadas normalizadas de los cuadros delimitadores y las etiquetas de clase correspondientes. La documentación del dataset incluye metadatos sobre las condiciones de captura, equipos utilizados, y parámetros de configuración para garantizar la reproducibilidad del estudio.[32]

3.3. Diseño de la propuesta

El diseño de la propuesta se estructura mediante una arquitectura modular que integra los componentes esenciales para el funcionamiento del sistema de visión artificial basado en YOLO. Esta arquitectura permite el procesamiento eficiente de imágenes de frutas en supermercados, desde la captura inicial hasta la generación de resultados cuantificables de detección y conteo.

3.3.1. Arquitectura del Sistema

La propuesta se fundamenta en una arquitectura secuencial compuesta por cinco módulos principales interconectados que procesan la información de manera sistemática. El diseño modular facilita la escalabilidad del sistema y permite optimizaciones independientes de cada componente, siguiendo las mejores prácticas establecidas en sistemas de visión artificial comerciales.[33]

El módulo de captura constituye el punto de entrada del sistema, responsable de adquirir imágenes únicas en alta resolución mediante cámaras RGB especializadas ubicadas estratégicamente en las estaciones de supermercado. Este componente implementa protocolos de calibración automática para garantizar la consistencia en la calidad de las imágenes bajo diferentes condiciones de iluminación.[33]

El módulo de preprocesamiento ejecuta operaciones de normalización, ajuste de contraste y reducción de ruido que optimizan la imagen para el procesamiento posterior mediante la red neuronal YOLO. Este componente implementa técnicas de mejora de imagen que han demostrado efectividad en aplicaciones similares de detección de productos alimentarios.[33]

3.3.2. Núcleo de Detección YOLO

El módulo de detección YOLO representa el núcleo del sistema, implementando la arquitectura de red neuronal convolucional entrenada específicamente para reconocer y localizar los tres tipos de frutas objetivo. El modelo procesa la imagen completa en una sola pasada, generando simultáneamente las coordenadas de los cuadros delimitadores, las probabilidades de clasificación y las puntuaciones de confianza para cada detección.[27]

La implementación utiliza YOLOv8 como base arquitectónica, aprovechando sus mejoras en precisión y velocidad de procesamiento comparado con versiones anteriores. El modelo se optimiza mediante técnicas de transfer learning utilizando pesos preentrenados en datasets generales, posteriormente refinados con el conjunto de datos específico de frutas.[27]

3.3.3. Módulo de Conteo y Validación

El módulo de conteo automático procesa las detecciones generadas por YOLO para cuantificar precisamente el número de frutas identificadas, implementando algoritmos especializados para resolver casos de oclusión y superposición. Este componente incorpora técnicas de supresión de no-máximos (NMS) mejoradas que reducen los falsos positivos y mejoran la precisión del conteo final.[30]

El módulo de validación y reporte genera la salida final del sistema, incluyendo estadísticas de detección, métricas de confianza y visualizaciones de los resultados. Este componente facilita la integración con sistemas existentes de punto de venta mediante interfaces estandarizadas de comunicación.[28]

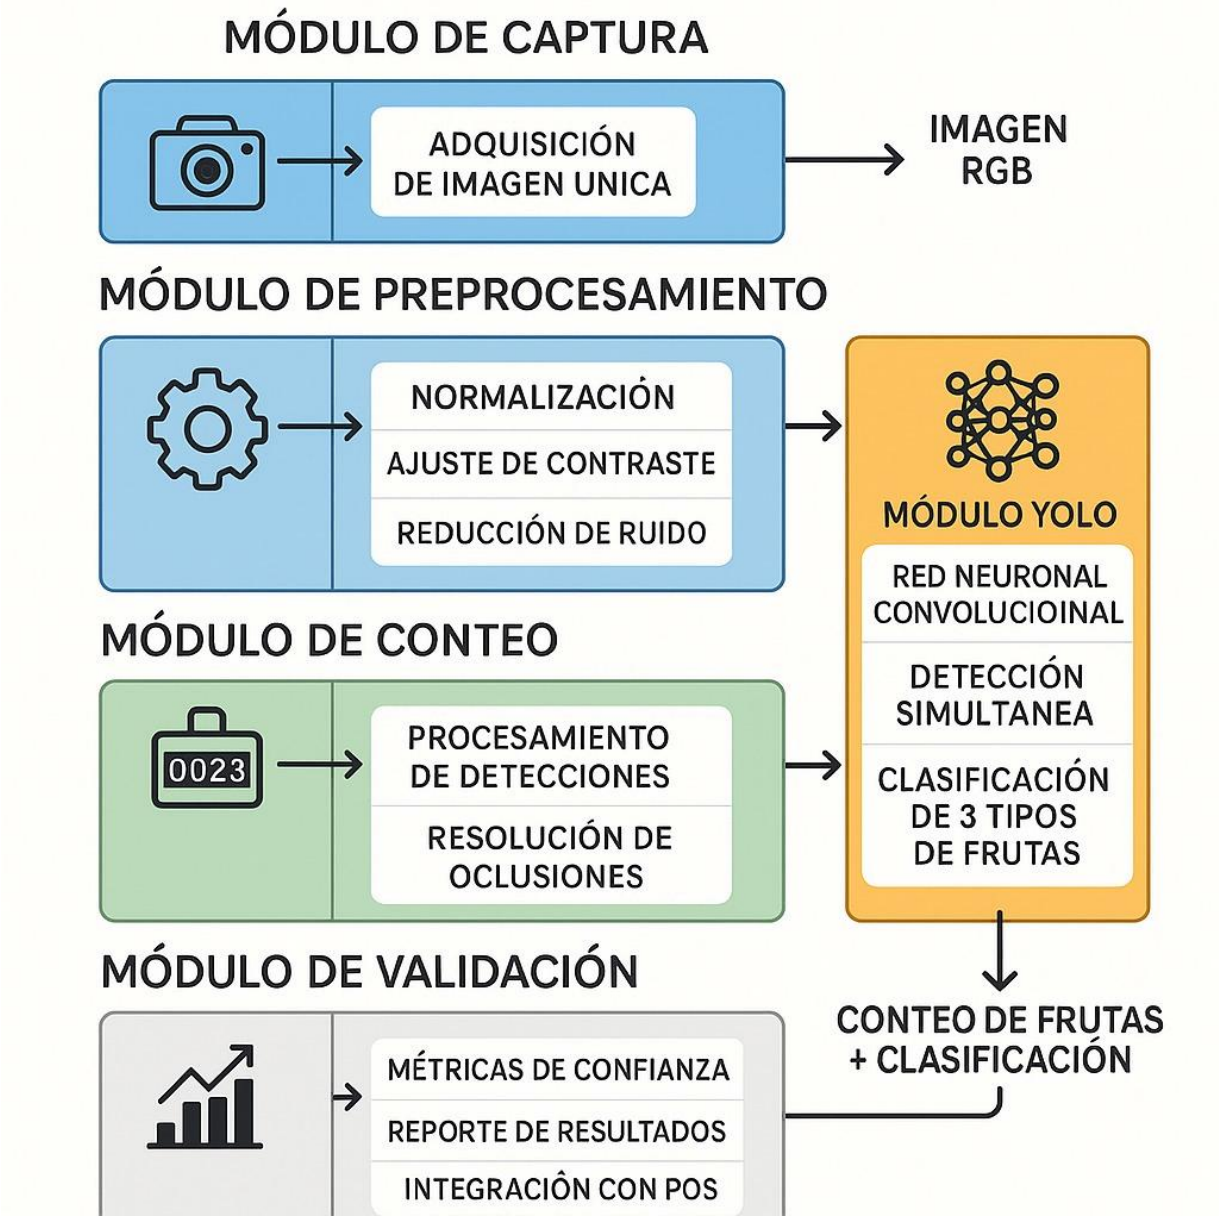


Ilustración 1. Arquitectura del sistema propuesto para la clasificación de frutas

3.3.4. Explicación del Flujo de Datos

El flujo de datos inicia con la captura de una imagen única que contiene múltiples frutas en condiciones típicas de supermercado. La imagen atraviesa el preprocesamiento donde se optimizan sus características visuales para maximizar la efectividad de la detección.

El procesamiento YOLO analiza la imagen completa dividida en una grilla de celdas, donde cada celda predice la presencia de objetos y sus respectivas clases. Las predicciones incluyen

coordenadas de cuadros delimitadores normalizados y probabilidades de clasificación para cada tipo de fruta.

El módulo de conteo agrega las detecciones individuales aplicando algoritmos de clustering espacial para resolver casos donde múltiples detecciones corresponden al mismo objeto físico. Finalmente, el sistema de validación verifica la coherencia de los resultados y genera reportes cuantificados listos para integración comercial.[26]

3.4. Diseño de la propuesta

El diseño experimental se estructura para evaluar de manera sistemática el rendimiento del sistema de visión artificial en condiciones representativas de supermercado. Se definen variables independientes y dependientes, tipos de experimentos, y procedimientos de recolección de datos para garantizar rigor y reproducibilidad.

Variables

Independientes: niveles de iluminación (bajo, medio, alto), grado de agrupamiento (aislado, pequeños racimos, grandes racimos), y ángulo de captura (frontal, lateral) de las imágenes.

Dependientes: precisión de detección, recall, F1-score, mAP, y tiempo de procesamiento por imagen.[31]

3.4.1. Diseño de los Experimentos

Se implementa un diseño factorial completo 3×3×3, generando 27 combinaciones de condiciones experimentales. Para cada combinación, se capturan 30 imágenes distintas, totalizando 810 imágenes de prueba. Esta muestra garantiza suficiente poder estadístico para detectar diferencias significativas en el desempeño del modelo

3.4.2. Procedimiento de Recolección

- En cada sesión experimental, se ajusta la iluminación mediante lámparas LED regulables y se fija el ángulo de captura con soportes calibrados.
- Las imágenes se organizan en carpetas etiquetadas según la combinación de condiciones.
- El sistema procesa cada carpeta de imágenes, generando un archivo CSV con las métricas de desempeño para cada imagen.

3.4.3. Procedimiento de recolección

Se verifica la consistencia de las condiciones experimentales midiendo la intensidad luminosa con un luxómetro y validando los ángulos con un goniómetro.

Se revisa aleatoriamente un 10% de las anotaciones del dataset de prueba para asegurar que las etiquetas de clase sean correctas antes de la ejecución de cada experimento.[26]

3.4.4. Procedimiento de recolección

Los resultados se presentan con intervalos de confianza del 90% y se visualizarán mediante gráficos de barras con barras de error para cada factor.

Este diseño garantiza una evaluación exhaustiva del sistema bajo condiciones variadas, permitiendo identificar las configuraciones óptimas para su implementación práctica en supermercados.[28]

3.5. Metodos para el procesamiento y análisis de resultados

Para garantizar una evaluación rigurosa del sistema de visión artificial, se definen los siguientes métodos de procesamiento y análisis de resultados, orientados a cuantificar el desempeño del modelo y extraer conclusiones fundamentadas.

En primer lugar, se calcularán las matrices de confusión para cada experimento, diferenciando los verdaderos positivos (TP), falsos positivos (FP), verdaderos negativos (TN) y falsos negativos (FN) en la detección y clasificación de frutas. Esto permitirá obtener métricas clave como precisión (TP/TP+FP) y recall (TP/TP+FN) para cada clase de fruta.[20]

A continuación, se derivará el F1-score como media armónica de precisión y recall para evaluar el equilibrio entre ambas métricas, así como el mAP (mean Average Precision) global, que reflejará la calidad promedio de las detecciones sobre todas las clases objetivo.[32]

El tiempo de procesamiento por imagen se medirá desde la recepción de la imagen en el módulo de captura hasta la salida del conteo final, registrando la latencia total del sistema. Estos datos se analizarán para verificar el cumplimiento de los requisitos de velocidad operativa en entornos de autoservicio.[30]

Para evaluar estadísticamente el impacto de las variables experimentales, se aplicará un ANOVA de tres factores (iluminación, agrupamiento y ángulo de captura) sobre cada métrica dependiente. En caso de obtener efectos significativos, se realizarán pruebas post hoc de Tukey para identificar diferencias entre niveles de factor específicos, adoptando un nivel de significación $\alpha=0.05$.[30]

Adicionalmente, se llevará a cabo un análisis de regresión múltiple para modelar la relación entre las variables independientes y el rendimiento del sistema, permitiendo predecir la precisión y el recall en configuraciones no evaluadas experimentalmente.[33]

Los resultados se visualizarán mediante gráficos de barras con barras de error para comparar métricas entre condiciones experimentales, así como diagramas de cajas (boxplots) que muestren la distribución del tiempo de procesamiento y las métricas de desempeño. Estas representaciones facilitarán la identificación de tendencias, variabilidad y posibles valores atípicos en los datos.[32]

Finalmente, se documentarán tablas resumen con los valores medios y desviaciones estándar de las métricas evaluadas en cada combinación experimental, acompañadas de los valores de p obtenidos en el ANOVA, para proporcionar una visión completa y detallada del comportamiento del sistema bajo diferentes escenarios.[33]

Fuentes bibliográficas

[1] J. L. Rojas-Aranda, J. I. Nunez-Varela, J. C. Cuevas-Tello, y G. Rangel-Ramirez, "Fruit Classification for Retail Stores Using Deep Learning," *Pattern Recognition*, vol. 12088, pp. 3–13, abr. 2020. doi: 10.1007/978-3-030-49076-8_1.

[2] J. Pinhammer, "Aldi Süd identifies fruit and vegetables with AI from Diebold Nixdorf," *Retail Optimiser*, Dec. 18, 2023. [Online]. Available: https://retail-optimiser.de/en/aldi-sued-identifies-fruit-and-vegetables-with-ai-from-diebold-nixdorf/.

[3] R. L. Sekar, N. Ambika, V. Divya, y T. Kowsalya, "Fruit Classification System Using Computer Vision: A Review," *International Journal of Trend in Research and Development*, vol. 5, no. 1, pp. 22–26, ene.-feb. 2018.

[4] Y. Xue y W. Q. Yan, "YOLO Models for Fresh Fruit Classification From Digital Videos," en *Handbook of Research on AI and ML for Intelligent Machines and Systems*. IGI Global, 2023, pp. 421–435.

[5] W. Zhang, J. Wang, Y. Liu, K. Chen, H. Li, Y. Duan, W. Wu, Y. Shi, y W. Guo, "Deep-learning-based in-field citrus fruit detection and tracking," *Hortic. Res.*, vol. 9, Art. no. uhac003, Feb. 2022.

[6] C. Dewi, D. Thiruvady, y N. Zaidi, "Fruit Classification System with Deep Learning and Neural Architecture Search," *arXiv*, 4 de jun. de 2024. Accedido: 10 de oct. de 2025. [Online]. Available: https://arxiv.org/abs/2406.01869.

[7] O. M. Lawal, S. Zhu, y K. Cheng, "An improved YOLOv5s model using feature concatenation with attention mechanism for real-time fruit detection and counting," *Front. Plant Sci.*, vol. 14, Art. no. 1153505, jun. 2023.

[8] L. Danev, "Fruit and vegetable classification from live video," Tesis de Maestría, School of Informatics, Univ. of Edinburgh, Edinburgh, U.K., 2017.

[9] B. M. Aviles Segarra y J. C. González Rosado, "SISTEMA DE VISIÓN ARTIFICIAL PARA EL RECONOCIMIENTO DE PRODUCTOS BÁSICOS EN LA PERCHA DE UN SUPERMERCADO," Tesis de Ing., Carrera de Mecatrónica, Univ. Politécnica Salesiana, Guayaquil, Ecuador, 2025.

[10] R. A. LEÓN LEÓN, D. A. DE LA CRUZ RAMOS, y A. D. RUBIO INFANTES, “Desarrollo de un algoritmo de visión artificial con redes neuronales convolucionales (YOLO V8) para el control de calidad de la mandarina Murcott,” en *Memorias de la Vigésima Tercera Conferencia Iberoamericana en Sistemas, Cibernética e Informática (CISCI 2024)*, 2024, pp. 440–446.

[11] J. A. Cardenas Franco, "Sistemas de Visión por Computadora para el control de Calidad," Tesis de Maestría, Univ. Politécnica de Tulancingo, Tulancingo de Bravo, Hidalgo, México, 2012.

[12] W. A. N. Horna y E. A. M. Ramos, “Sistema de visión artificial basado en redes neuronales convolucionales para la selección de arándanos según estándares de exportación,” *Campus*, vol. 26, no. 32, jul.–dic. 2021.

[13] SeeChange, "Solving self-checkout problems: Vision AI tackles the fresh produce pain point," SeeChange Technologies, 18 de jul. de 2025. [Online]. Available: https://seechange.com/self-checkout-problems-fresh-produce-vision-ai/.

[14] W. A. N. Horna y E. A. M. Ramos, “Sistema de visión artificial basado en redes neuronales convolucionales para la selección de arándanos según estándares de exportación,” *Campus*, vol. 26, no. 32, jul.–dic. 2021.

[15] Y. Xue y W. Q. Yan, "YOLO Models for Fresh Fruit Classification From Digital Videos," en *Handbook of Research on AI and ML for Intelligent Machines and Systems*. IGI Global, 2023, pp. 421–435.

[16] fruit yolov8, "Fruit label Dataset," *Roboflow Universe*, 2025. Accedido: 10 de oct. de 2025. [Online]. Available: https://universe.roboflow.com/fruit-yolov8-npgyc/fruit-label.

[17] O. M. Lawal, S. Zhu, y K. Cheng, "An improved YOLOv5s model using feature concatenation with attention mechanism for real-time fruit detection and counting," *Front. Plant Sci.*, vol. 14, Art. no. 1153505, jun. 2023.

[18] W. A. N. Horna y E. A. M. Ramos, “Sistema de visión artificial basado en redes neuronales convolucionales para la selección de arándanos según estándares de exportación,” *Campus*, vol. 26, no. 32, jul.–dic. 2021.

[19] R. A. LEÓN LEÓN, D. A. DE LA CRUZ RAMOS, y A. D. RUBIO INFANTES, “Desarrollo de un algoritmo de visión artificial con redes neuronales convolucionales (YOLO V8) para el control de calidad de la mandarina Murcott,” en *Memorias de la Vigésima Tercera Conferencia Iberoamericana en Sistemas, Cibernética e Informática (CISCI 2024)*, 2024, pp. 440–446.

[20]R. A. León León, J. C. Morales Salazar, and M. B. Alcalde Portal, “Desarrollo de un Algoritmo de Visión Artificial mediante Redes Neuronales Convolucionales YOLO v8 para la Clasificación de Espárragos según la Yema,” Memorias de la Conferencia Iberoamericana en Sistemas, Cibernética e Informática, pp. 497–504, Sep. 2024, doi: https://doi.org/10.54808/cisci2024.01.497.

[21]“Clasificación por Deep Learning – INSPECTRA,” Inspectra-vision.com, 2025. https://inspectra-vision.com/clasificacion-por-deep-learning/ (accessed Oct. 09, 2025).

[22]C. Shen, R. Wang, H. Nawazish, B. Wang, K. Cai, and B. Xu, “Machine vision combined with deep learning–based approaches for food authentication: An integrative review and new insights,” Comprehensive Reviews in Food Science and Food Safety, vol. 23, no. 6, Nov. 2024, doi: https://doi.org/10.1111/1541-4337.70054.

[23]G. De, U. Supermercado, and quot; Súper, “HERRAMIENTAS DE ANÁLISIS CUANTITATIVO IMPLEMENTADAS EN LA ESTEBAN ALCAIDE -FACUNDO CAMANDONA - SIXTINA MASINO - FIORELLA PEREZ FRARESSO -IVÁN PREDOVIC -RODRIGO SEMRIK.” Accessed: Oct. 09, 2025. [Online]. Available: https://face.unt.edu.ar/web/iadmin/wp-content/uploads/sites/2/2024/05/A12-Herramientas-de-analisis-cuantitativo-implementadas-en-la-gestion-de-un-supermercado.pdf

[24]M. Romano, “Puesta en marcha de un proyecto de Deep Learning para la producción, parte 2: recolección de datos y obtención de información real,” Cognex.com, Jul. 20, 2022. https://www.cognex.com/es-mx/blogs/deep-learning/starting-a-deep-learning-project-collecting-data-and-establishing-ground-truth (accessed Oct. 09, 2025).

[25]R. A. León León, C. A. Barrantes Vargas, and F. D. Bacilio De La Cruz, “Desarrollo de un Sistema de Visión Artificial con la Red Neuronal Convolucional (YOLO v8) para Clasificar el Arándano por su Grado de Madurez,” Memorias de la Conferencia Iberoamericana en Sistemas, Cibernética e Informática, pp. 475–482, Sep. 2024, doi: https://doi.org/10.54808/cisci2024.01.475.

[26]I. Agdestein, “Etiquetado y anotación de datos para la IA,” Focalx – Inspección de vehículos impulsada por IA, Feb. 27, 2025. https://focalx.ai/es/inteligencia-artificial-es/etiquetado-y-anotacion-de-datos-para-la-ia-la-base-del-aprendizaje-automatico/ (accessed Oct. 09, 2025).

[27]B. Dwyer, “Synthetic Image Data Generation for Computer Vision,” Roboflow Blog, Apr. 15, 2020. https://blog-roboflow-com.translate.goog/how-to-create-a-synthetic-dataset-for-computer-vision/?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc (accessed Oct. 09, 2025).

[28]Ultralytics, “SKU-110K,” Ultralytics.com, 2023. https://docs.ultralytics.com/es/datasets/detect/sku-110k/ (accessed Oct. 09, 2025).

[29]B. Valenzuela et al., “SISTEMA PARA DETECCIÓN DE OBJETOS MEDIANTE VISION ARTIFICIAL IMPLEMENTADO EN ARQUITECTURA ARM PARA APLICACIONES DE NAVEGACIÓN AUTÓNOMA,” Revista ELECTRO, vol. 46, pp. 369–373, 2024, Accessed: Oct. 09, 2025. [Online]. Available: https://www.itchihuahua.mx/revista_electro/2024/A41_369-373.pdf

[30]“YOLO: un detector de objetos en tiempo real,” Innovatiana.com, 2024. https://www.innovatiana.com/es/post/what-is-yolo-in-ai (accessed Oct. 09, 2025).

[31]M. Magdin and Z. Balogh, “Comparison classification algorithms and the YOLO method for video analysis and object detection,” Scientific Reports, vol. 15, no. 1, Jul. 2025, doi: https://doi.org/10.1038/s41598-025-09814-1.

[32]E. San et al., “MODELO DEEP LEARNING PARA MEJORAR LA PREDICCIÓN DE LAS VENTAS EN LA Tesis para optar el Título Profesional de Ingeniero de Sistemas (CC BY-NC-ND).” Available: https://repositorio.unfv.edu.pe/bitstream/handle/20.500.13084/8850/UNFV_FIIS_Suarez%20Romero%20Alexander%20Cristhian_Titulo%20profesional_2024.pdf?sequence=1&isAllowed=y

[33]“Introducción a la Investigación Cuantitativa.” Available: https://www.centro-virtual.com/recursos/biblioteca/pdf/investigacion_cuantitativa/unidad1_pdf1.pdf